

Baseline: bhw2_gru.ipynb

1. Описание архитектуры - baseline

В качестве базовой архитектуры я выбрал модель Seq2Seq с механизмом внимания Bahdanau(additive attention). Выбрал такое сочетание так как эта связка хорошо подходит для данных малого и среднего размеров

1.1. Encoder

Кодировщик реализован как двунаправленный GRU- Bidirectional GRU. Я подумал, что лучше чтобы каждое слово знало контекст предыдущего и будущего, так как читает только слева на право. Теперь в обе стороны. Взял GRU в целом, так как он проще чем lstm, быстрее обучается, не хуже по качеству.

Выходы кодировщика:

- `encoder_outputs` — контекстуализированные представления всех токенов, размерность `hidden_dim × 2`
- `hidden` — финальное скрытое состояние для инициализации декодировщика

1.2. Attention

Выбрал Bahdanau attention, так как он изначально был создан для задачи перевода и позволяет декодеру на каждом шаге фокусироваться на нужных словах входного предложения

1.3. Decoder

Декодировщик — однонаправленный GRU с attention:

1. Текущий входной токен преобразуется через `embedding + dropout`
2. На основе скрытого состояния верхнего слоя и выходов энкодера вычисляется контекстный вектор через attention
3. Конкатенация `[embedding, context]` подаётся на вход gru
4. Выход gru, контекстный вектор и `embedding` конкатенируются для финального предсказания:
`fc_out([output, context, embedded])`

Эта схема следует рекомендациям Luong et al. и позволяет модели учитывать как текущий контекст, так и текущее входное слово при генерации.

2. Детали обучения

2.1. Базовые гиперпараметры

Параметр	Значение
Embedding dim	256
Hidden dim	512
Attention dim	256
Num layers (encoder + decoder)	2
Dropout	0.3
Batch size	256

Параметр	Значение
Epochs	10
Optimizer	Adam
Learning rate	1e-3
LR scheduler	ReduceLROnPlateau (factor=0.5, patience=3)
Gradient clipping	1.0
Teacher forcing	линейно: 1.0 $\rightarrow$ 0.5
Декодирование	Greedy (argmax)

2.2. Teacher Forcing

Я решил использовать teacher forcing для того, чтобы снизить проблему накопления ошибки предсказания следующего слова. Я поставил показатель Teacher forcing ratio = 1 в самом начале. Но тогда, возникает разрыв между условиями обучения и инференса - exposure bias и чтобы это сгладить я уменьшаю показатель до 0.5, чтобы она видела свои предсказания и привыкала к ним.

3. Эксперименты

Baseline

Логи

Epoch	TF	Train Loss	Val Loss	PPL	BLEU
1	1.00	4.3571	6.5666	710.98	12.96
2	0.94	3.0297	5.9585	387.02	21.59
3	0.89	2.5719	5.7290	307.66	23.42
4	0.83	2.3494	5.5746	263.64	23.80
5	0.78	2.2665	5.4847	240.99	23.48
6	0.72	2.2326	5.3278	205.99	24.02
7	0.67	2.2392	5.3334	207.14	24.24
8	0.61	2.2669	5.1185	167.08	22.98
9	0.56	2.3101	5.0728	159.62	23.36
10	0.50	2.3574	4.9343	138.97	22.62

Best BLEU: 24.24 на эпохе 7

Train loss стабильно снижается с 4.36 до 2.36. Val loss тоже уменьшается, но разрыв с train loss большой — модель переобучается. BLEU достигает пика на эпохе 7 и затем немного снижается, видимо из-за снижения teacher forcing ratio.

Примеры переводов Модель хорошо справляется с простыми предложениями. но есть проблемы: потеря смысла в длинных предложениях как в примере 1 и перестановка структуры как в примере 2

Эксперимент 2: Beam Search декодирование

Greedy декодирование выбирает самое лучшее слово локально на каждом шаге, но это не гарантирует что оно лучшее глобально. Попробую это исправить с beam search, который рассматривает несколько гипотез одновременно.




Figure 1: Графики обучения baseline модели

```

best BLEU: 24.02 saved!
Train: 100%|██████████| 766/766 [12:56<00:00, 1.01s/it]
Val: 100%|██████████| 4/4 [00:00<00:00, 4.05it/s]
That's 100 lines that end in a tokenized period ('.')
It looks like you forgot to detokenize your test data, which may hurt your score.
If you insist your data is detokenized, or don't care, you can suppress this message with the `force` parameter.
Epoch 07/10 | TF: 0.67 | LR: 0.001000 | Train: 2.2392 | Val: 5.3334 | PPL: 207.14 | BLEU: 24.24 | 777s
HYP: when i was 11 years old , i grew one morning by the morning .
REF: when i was 11 , i remember waking up one morning to the sound of joy in my house .

HYP: my father listened to his little , gray radio <unk> the <unk> of the bbc .
REF: my father was listening to bbc news on his small , gray radio .

HYP: he looked very happy , which was unusual , then he was the most <unk> , the news .
REF: there was a big smile on his face which was unusual then , because the news mostly depressed him .

best BLEU: 24.24 saved!
Train: 100%|██████████| 766/766 [12:56<00:00, 1.01s/it]
Val: 100%|██████████| 4/4 [00:00<00:00, 4.06it/s]
That's 100 lines that end in a tokenized period ('.')
It looks like you forgot to detokenize your test data, which may hurt your score.
If you insist your data is detokenized, or don't care, you can suppress this message with the `force` parameter.
Epoch 08/10 | TF: 0.61 | LR: 0.001000 | Train: 2.2669 | Val: 5.1185 | PPL: 167.08 | BLEU: 22.98 | 777s
HYP: when i was 11 years old , i became one morning in the morning of the .
REF: when i was 11 , i remember waking up one morning to the sound of joy in my house .

HYP: my father listened to his little , little radio , the <unk> of the bbc .
REF: my father was listening to bbc news on his small , gray radio .

HYP: he looked very happy what he was quite unusual , because he him the most well-known times .
REF: there was a big smile on his face which was unusual then , because the news mostly depressed him .

Train: 100%|██████████| 766/766 [12:56<00:00, 1.01s/it]
Val: 100%|██████████| 4/4 [00:00<00:00, 4.07it/s]
That's 100 lines that end in a tokenized period ('.')
It looks like you forgot to detokenize your test data, which may hurt your score.
If you insist your data is detokenized, or don't care, you can suppress this message with the `force` parameter.
Epoch 09/10 | TF: 0.56 | LR: 0.001000 | Train: 2.3101 | Val: 5.0728 | PPL: 159.62 | BLEU: 23.36 | 778s
HYP: when i was 11 years old , i was one morning by the the of the sound of joy .
REF: when i was 11 , i remember waking up one morning to the sound of joy in my house .

```

Figure 2: Примеры переводов на валидационной выборке

Реализован beam search с beam_size = 5. Нормализация длины предотвращает смещение в сторону коротких переводов.

будем применять уже к обученной модели на эксперименте 1

```
[30]: # beam search эксперимент
ckpt = torch.load(SAVE_PATH, map_location=device, weights_only=False)
model.load_state_dict(ckpt["model_state_dict"])
model.eval()

beam_translations = []
for batch in tqdm(val_loader, desc="Beam Search"):
    src, _, src_lens, _ = batch
    src = src.to(device)
    src_lens = src_lens.to(device)
    decoded = model.beam_search_translate(src, src_lens, beam_size=5)
    for token_ids in decoded:
        tokens = train_dataset.trg_vocab.decode(token_ids)
        beam_translations.append(" ".join(tokens))

beam_bleu = sb.corpus_bleu(beam_translations, [val_references], tokenize="none").score
print(f"Greedy BLEU: 24.24")
print(f"Beam Search BLEU (k=5): {beam_bleu:.2f}")

Last executed at 2026-03-15 23:09:37 in 2m 31.91s

Beam Search: 100%|██████████| 4/4 [02:20<00:00, 35.15s/it]
That's 100 lines that end in a tokenized period ('.')
It looks like you forgot to detokenize your test data, which may hurt your score.
If you insist your data is detokenized, or don't care, you can suppress this message with the `force` parameter.

Greedy BLEU: 24.24
Beam Search BLEU (k=5): 26.60
```

Figure 3: beam_search_screenshot

Декодирование	Val BLEU	Δ BLEU
Greedy	24.24	—
Beam Search (k=5)	26.60	+2.36

Beam search дал +2.36 blue без переобучения. Значит, greedy декодировщик правда имел проблему с застриванием в локальном оптимуме.

Переход на Transformer

GRU-модель ограничена последовательной обработкой и достигла потолка где BLEU примерно 26 с beam search. Перешёл на архитектуру Transformer (Vaswani et al., 2017), которая использует multi-head self-attention и позволяет параллельную обработку.

Параметр	Значение
d_model	256
Головы	8
Слои (enc + dec)	3 + 3
FFN	512
Dropout	0.1
Label smoothing	0.1
LR schedule	Noam warmup (4000 шагов)




Figure 4: Графики обучения Transformer

Графики обучения Train loss снижается достаточно стабильно. Val loss выходит на плато после примерно 6 эпохи. BLEU растёт до 31+ к 15 эпохе. Learning rate сначала растёт, потом плавно снижается.

```
Loaded best model: epoch 15, BLEU 31.08
Translate: 100%|██████████| 12/12 [00:05<00:00, 2.39it/s]
wrote 2998 translations to test1.de-en.en
Translate: 100%|██████████| 4/4 [00:01<00:00, 2.36it/s]
That's 100 lines that end in a tokenized period ('.')
It looks like you forgot to detokenize your test data, which may hurt your score.
If you insist your data is detokenized, or don't care, you can suppress this message with the `force` parameter.
final validation BLEU: 31.08
SRC: als ich 11 jahre alt war , wurde ich eines morgens von den klängen heller freude geweckt .
HYP: when i was 11 years old , i was introduced one morning by the sound of the sound .
REF: when i was 11 , i remember waking up one morning to the sound of joy in my house .

SRC: mein vater hörte sich auf seinem kleinen , grauen radio die nachrichtensendung der bbc an .
HYP: my dad heard on his little , gray , radio , the <unk> of the bbc ,
REF: my father was listening to bbc news on his small , gray radio .

SRC: er sah sehr glücklich aus , was damals ziemlich ungewöhnlich war , da ihn die nachrichten meistens deprimierten .
HYP: he looked very happy , which was quite unusual at the time , because it was the news mostly .
REF: there was a big smile on his face which was unusual then , because the news mostly depressed him .

SRC: er rief : " die taliban sind weg ! "
HYP: he called , " the taliban are gone ! "
REF: " the taliban are gone ! " my father shouted .

SRC: ich wusste nicht , was das bedeutete , aber es machte meinen vater offensichtlich sehr , sehr glücklich .
HYP: i didn 't know what that meant , but it made my father obviously very , very happy .
REF: i didn 't know what it meant , but i could see that my father was very , very happy .
```

Figure 5: Переводы Transformer

Примеры переводов видно что качество переводов значительно улучшилось, предложения стали более грамматичные и точнее передают смысл по сравнению с GRU

Эксперимент 3: Beam Search + трансформер

мотивация : как и в gnn попробуем использовать beam search, так как мы на каждом шаге в процессе авторегрессионного режима будем предсказывать не одно слово (токен), а к лучшим слов, для того чтобы уменьшить накоп ошибки. Так же у gnn это дало улучшение метрики.

```
Beam Test: 100%|██████████| 12/12 [18:22<00:00, 91.91s/it]
Wrote 2998 beam translations
Beam Val: 100%|██████████| 4/4 [06:36<00:00, 99.06s/it]
That's 100 lines that end in a tokenized period ('.')
It looks like you forgot to detokenize your test data, which may hurt your score.
If you insist your data is detokenized, or don't care, you can suppress this message with the `force` parameter.
beam search blue k=5 32.12
```

Figure 6: Beam Search Transformer

Декодирование	Val BLEU	Δ BLEU
Greedy	31.08	—
Beam Search (k=5)	32.12	+1.04

Как видно, улучшение так же присутствует

Эксперимент 4: Увеличение D_{FF} и числа эпох

Мотивация: в оригинальной статье (Vaswani et al.) используется $D_{FF} = 4 \times d_{model}$. Попробуем увеличить D_{FF} с 512 до 1024 (4×256) и количество эпох с 15 до 20 для дальнейшего улучшения качества.

Параметр	Было	Стало
D_{FF}	512 (2×)	1024 (4×)
NUM_EPOCHS	15	20




Figure 7: Графики обучения Transformer v2

Графики обучения


```

Loaded best model: epoch 17, BLEU 31.83
Translate: 100%|██████████| 12/12 [00:05<00:00, 2.16it/s]
wrote 2998 translations to test1.de-en.en
Translate: 100%|██████████| 4/4 [00:01<00:00, 2.15it/s]
That's 100 lines that end in a tokenized period ('.')
It looks like you forgot to detokenize your test data, which may hurt your score.
If you insist your data is detokenized, or don't care, you can suppress this message with the `force` parameter.
final validation BLEU: 31.83
SRC: als ich 11 jahre alt war , wurde ich eines morgens von den klängen heller freude geweckt .
HYP: when i was 11 years old , i became blown away by the sound happy .
REF: when i was 11 , i remember waking up one morning to the sound of joy in my house .

SRC: mein vater hörte sich auf seinem kleinen , grauen radio die nachrichtensendung der bbc an .
HYP: my father stopped his little , gray radio radio radio , the <unk> on the bbc .
REF: my father was listening to bbc news on his small , gray radio .

SRC: er sah sehr glücklich aus , was damals ziemlich ungewöhnlich war , da ihn die nachrichten meistens deprimiert
en .
HYP: he looked very happy , which was quite unusual then , because he was mostly <unk> the news .
REF: there was a big smile on his face which was unusual then , because the news mostly depressed him .

SRC: er rief : " die taliban sind weg ! "
HYP: he called , " the taliban are gone ! "
REF: " the taliban are gone ! " my father shouted .

SRC: ich wusste nicht , was das bedeutete , aber es machte meinen vater offensichtlich sehr , sehr glücklich .
HYP: i didn 't know what that meant , but it made my father very , very happy .
REF: i didn 't know what it meant , but i could see that my father was very , very happy .

```

Figure 8: Примеры переводов Transformer v2

Примеры переводов Val BLEU вырос незначительно с 31.08 до 31.83, лучшее значение на эпохе 17, однако на публичной тестовой выборке результат стал чуть хуже. Это значит что трансформер переобучился.

Beam search (k=5) на этой модели так же не помог превзойти базовый конфиг:

```

Beam Test: 100%|██████████| 12/12 [17:59<00:00, 89.96s/it]
Wrote 2998 beam translations
Beam Val: 100%|██████████| 4/4 [06:34<00:00, 98.65s/it]
That's 100 lines that end in a tokenized period ('.')
It looks like you forgot to detokenize your test data, which may hurt your score.
If you insist your data is detokenized, or don't care, you can suppress this message with the `force` parameter.
beam search blue k=5 32.60

```

Figure 9: Beam Search Transformer v2

На публичном тесте: 29.01 (vs 29.03 у базового конфига + beam search). Вывод: увеличение ёмкости модели без увеличения объёма данных ведёт к переобучению.

4. Сводная таблица результатов

#	Эксперимент	Val BLEU	Примечания
1	GRU Baseline (Greedy)	24.24	Best на эпохе 7
2	GRU + Beam search (k=5)	26.60	+2.36, без переобучения
3	Transformer (Greedy)	31.08	Best на эпохе 15

#	Эксперимент	Val BLEU	Примечания
4	Transformer + Beam search (k=5)	32.12	+1.04, без переобучения
5	Transformer (D_FF=1024, 20 эпох)	31.83	Переобучение, результат на тесте хуже
6	Transformer v2 + Beam search (k=5)	32.87	Публичный тест 29.01, хуже базового

5. Литература

1. Bahdanau D., Cho K., Bengio Y. "Neural Machine Translation by Jointly Learning to Align and Translate." ICLR, 2015.
2. Cho K. et al. "Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation." EMNLP, 2014.
3. Luong M., Pham H., Manning C. "Effective Approaches to Attention-based Neural Machine Translation." EMNLP, 2015.
4. Vaswani A. et al. "Attention Is All You Need." NeurIPS, 2017.